Izveštaj o OCR greškama: učestalost, uzroci i profil uspeha/neuspeha

December 25, 2025

1 Sažetak

Analiziran je skup od pet dokumenata (ukupno 114 linija teksta) za koje je dostupno poređenje *OCR izlaza* i *ground truth* (tačan tekst). Ukupna tačnost po liniji je 36/114 = 31.6%. Jedan dokument pokazuje potpuni raspad *layout/segmentacije* (0/26 tačnih linija), što snažno obara globalni rezultat. Kada se taj dokument isključi, tačnost raste na 36/88 = 40.9%.

Najčešće greške su:

- **Zamena kanđija (wrong kanji)**: 23/78 pogrešnih linija (29.5%).
- **Pogrešan sadržaj (wrong content)**: 17/78 (21.8%) — tipično zbog čitanja pogrešnog polja/regiona.
- **Izostavljeni karakteri (missing characters)**: 10/78 (12.8%).
- **Izostavljen jedan karakter (missing character)**: 6/78 (7.7%).
- **Spajanje bez razmaka (missing space)**: 3/78 (3.8%).

Kritičan zaključak: najveći izvor katastrofalnih grešaka nije ”pogrešno slovo”, već **pogrešno detektovan raspored (layout) i segmentacija regiona**. Kanđi-supstitucije su česte, ali su često **lokalne** i potencijalno popravljive post-procesiranjem; layout greške su **sistemske** i ”pomere” ceo izlaz.

2 Podaci i metodologija

2.1 Skup dokumenata

Analiza pokriva 5 dokumenata (u opisima: vozačka dozvola, pasoš, dve varijante zdravstvene kartice, i dokument/legitimacija tipa “消防設備士免状”). Ukupno je analizirano 114 linija teksta.

2.2 Metod merenja

- Jedinica merenja: **linija** (line-by-line poređenje OCR i ground truth).
- Linija se računa kao **tačna** ako je označena kao “Correct”, inače kao **netačna**.

- Tip greške uzima se kao **primarna etiketa** iz postojeće analize svake linije (npr. “Wrong kanji”, “Missing space”, “Wrong content”, itd.).

3 Rezultati: tačnost po dokumentu

Table 1: Tačnost po dokumentu (linijski nivo)

Dokument	Ukupno linija	Tačno	Tačnost
Vozačka dozvola (JP)	21	9	42.9%
Pasoš (JP/EN)	16	7	43.8%
Zdravstvena kartica A	22	6	27.3%
Zdravstvena kartica B	29	14	48.3%
“消防設備士免状” tip dokumenta	26	0	0.0%
Ukupno	**114**	**36**	**31.6%**

Napomena. Dokument sa 0% je tipičan primer **layout/segmentacionog kvara**: OCR tekst nije ”besmislen”, ali je uglavnom **uziman iz pogrešnih zona** (mešanje labela, vrednosti, redova/kolona), pa se sve kaskadno pomera.

4 Taksonomija grešaka

U praksi, najkorisnije je razlikovati greške po **uzroku** (šta je pošlo naopako u pipeline-u), a ne samo po površinskom opisu. U nastavku su dve komplementarne klasifikacije:

4.1 Primarne etikete (kako su greške obeležene)

U 78 netačnih linija (114 ukupno minus 36 tačnih), primarne etikete se pojavljuju ovako:

Table 2: Učestalost primarnih tipova grešaka (od 78 pogrešnih linija)

Primarni tip greške	Broj	Udeo
Wrong kanji	23	29.5%
Wrong content	17	21.8%
Missing characters	10	12.8%
Missing character	6	7.7%
Missing space	3	3.8%
Extra character	2	2.6%
Wrong numeral / numeral format	2	2.6%
Punctuation error	1	1.3%
Incorrect text / segmentation	1	1.3%
Erroneous format	1	1.3%
Wrong interpretation	1	1.3%
Incorrect context	1	1.3%
Wrong characters (full/half-width)	1	1.3%

4.2 Kausalne grupe (šta realno ”lomi” OCR)

Ovo je praktičnije za inženjerske odluke (šta popravljati prvo):

- **(A) Kanđi supstitucija / konfuzija znakova** — vizuelno slični kanđiji, često uz ”JP vs CN” varijante.
- **(B) Layout/segmentacija regiona** — pogrešno odabrano polje/kolona; ”pomeren” red; pogrešan region slike.
- **(C) Dropout (izostavljanje znakova)** — tanke linije nestanu, loše binarizovanje, loše razdvajanje karaktera.
- **(D) Razmaci i normalizacija širine** — half-width vs full-width (npr. ２ vs 2, A T vs AT), razmaci u imenima/datumima.
- **(E) Interpunkcija** — zagrade, crtice, razdvajanje blokova broja (telefon).

5 Detaljna analiza po tipu greške

5.1 A) Zamena kanđija (Wrong kanji): zašto je tako česta?

Ovo je najčešća pojedinačna etiketa. Dva dominantna mehanizma:

A1: Vizuelno slični znakovi (radikali, potezi). Primeri iz skupa jasno pokazuju supstitucije tipa:

- 令和 → 今和 ili 分和 (zamena 令 sa 今 ili 分).
- 世帯 → 世蒂 (帯 zamenjen sa 蒂).
- 有効 → 有效 (zamena ”効” sa kineskom varijantom/alternativnim znakom).
- 性別 → 性别 (别 → 别).

Ovo se dešava kada je rezolucija mala, kontrast slab, ili font/štampa imaju tanke poteze. Model ”pogodi” približan oblik, ali promaši tačan Unicode znak.

A2: JP vs CN varijante (“hanzi” vs “kanji” normalizacija). Kada OCR sistem ili jezički model nije strogo ”Japanese-only”, zna da ”klizne” u kineske varijante: 有効/有效, 性別/性别. Vizuelno su slični, ali u verifikaciji teksta to je greška.

Posledica. Ove greške su često **lokalne** i ponekad popravljive:

- rečnikom/frekventnim frazama (npr. 令和 je ekstremno verovatno u zvaničnim dokumentima),
- jezičkom normalizacijom na ”JP varijante”,
- post-procesiranjem zasnovanim na kontekstu polja (datum, adresa, prefektura, itd.).

5.2 B) Layout/segmentacija (Wrong content): najveći izvor katastrofe

Wrong content je često simptom da OCR nije čitao ”pogrešno slovo” nego **pogrešan region dokumenta**. Tipični obrasci:

- vrednost iz jedne kolone prepisana na mesto labele iz druge kolone,
- serijski brojevi ”upadaju” gde treba da stoji opis polja,
- redovi se rotiraju/pomeraju: linija n iz OCR-a odgovara truth-u iz linije $n+1$ ili $n-1$,
- kompletan ”drift”: skoro nijedna linija se ne poklapa (najgori dokument: 0/26).

Zašto se to dešava. Ovo je klasičan problem kod dokumenata sa više zona (tabele, okvirčići, više fontova, vertikalni/hor. tekst):

- detekcija teksta (text detection) pogrešno grupiše blokove,
- čitanje redosleda (reading order) pogrešno sortira regiona,
- pre-crop/deskew greške: mali nagib ili crop ”odseče” delove ili pomeri koordinatni sistem.

Posledica. Layout greške su **sistemske**: ako pogrešiš raspored, i savršena prepoznatljivost karaktera ti ne pomaže. Ovo je prioritet #1 za popravku pipeline-a.

5.3 C) Izostavljeni karakteri (Missing characters / Missing character)

Ovo se manifestuje kao:

- ”ispao” deo fraze ili cela reč,
- izostao label (npr. “番号” nedostaje, ostane samo broj),
- izostao deo imena ili sufiks (npr. deo punog imena).

Zašto. Najčešći uzroci:

- preagresivno čišćenje šuma (denoise) i binarizacija,
- tanke linije i mali fontovi ”nestanu”,
- loše razdvajanje karaktera u gustim delovima (posebno kanđi sa mnogo poteza).

Napomena. Često ide zajedno sa (B): kada je region pogrešno isečen, neki karakteri ”ispadnu” na ivici.

5.4 D) Razmaci i širina znakova (full-width/half-width normalizacija)

Ovo je ”tihi ubica” validacije: čovek pročita isto, ali string nije isti.

Tipični primeri.

- full-width cifre: ６８ vs 68, ili adresa ２－４－６－２０－２０５ vs 2-4-6-20-205,
- latinica: AT vs ＡＴ,
- razmaci u datumima: “昭和 60 年 5 月 28 日” vs “昭和 60 年 5 月 28 日”,
- full-width space između imena: “藤田　洋子” (full-width razmak) vs “藤田 洋子”.

Zašto. OCR često ne razlikuje ”tipografski razmak” od realnog razmaka ili bira pogrešnu Unicode varijantu (zenkaku/hankaku). To je posebno često u japanskim zvaničnim dokumentima gde su zenkaku cifre i simboli standard.

Implikacija. Ovo je često najlakše rešivo post-procesiranjem:

- normalizacija razmaka (više razmaka → jedan, ili očuvanje prema pravilima polja),
- normalizacija zenkaku/hankaku prema očekivanom standardu (ili obrnuto),
- normalizacija zagrada/telefonskih formata.

5.5 E) Interpunkcija (retko, ali vidljivo)

U uzorku se javlja i pogrešno prepoznavanje zagrada i razmaka u telefonskom broju:

0299（90)1111 vs 0299(90) 1111

Ovo obično dolazi iz kombinacije (D) normalizacije + (C) izostavljanja razmaka.

6 Šta OCR radi dobro, a šta loše (profil uspeha/neuspeha)

6.1 Kada OCR radi dobro

Najstabilniji slučajevi u ovom skupu:

- **Čista latinica velikim slovima**: npr. `PASSPORT`, `JAPAN`, `GAIMU`, `NATSUKO`.
- **Jednostavni, kratki kanđi labeli** sa dobrim kontrastom: npr. 氏名, 住所, 生年月日 (u delovima gde layout nije problem).
- **Neki numerički nizovi** (npr. `MJ4564879`, `1213488`) — ali samo ako nisu u layout zoni koja ”klizi”.

6.2 Kada OCR radi loše

Najpouzdaniji ”fail” patterni:

- **Dokumenti sa jakim layout-om** (tabele, više okvira, više kolona, složen reading order). Tu se javlja “wrong content” i sistemski drift.
- **Kanđi sa sličnim oblicima i mnogo poteza** (radikali koji liče), pogotovo pri niskoj rezoluciji.

- **JP/CN varijantne zamene** (有効/有效, 性別/性别) — znak da pipeline nije strogo vezan za japanski standard.
- **Zenkaku/hankaku problemi** (2 vs ２, - vs －, AT vs ＡＴ) — ”izgleda isto”, ali string nije isti.

7 Apendiks A: primeri tipičnih konfuzija (Unicode vidljiv)

Ovaj apendiks služi kao ”mini katalog” grešaka koje se uočavaju u skupu.

Kanđi supstitucije (JP/CN i vizuelna sličnost)

- 令和 → 今和, 分和
- 有効 → 有效
- 性別 → 性别
- 世帯 → 世蒂
- 茨城県 → ☒城☒

Full-width / Half-width

- ２－４－６－２０－２０５ ↔ 2-4-6-20-205
- AT ↔ ＡＴ
- ６８ ↔ 68
- (90) ↔ (90)

Razmaci i spajanje

- 昭和60年5月28日 ↔ 昭和60年5月28日
- 藤田 洋子 ↔ 藤田　洋子

8 Apendiks B: Detaljna analiza po dokumentu

U ovoj sekciji prikazani su konkretni rezultati OCR analize za pet različitih dokumenata. Za svaki dokument dat je originalni scan, tabela sa metrikama performansi, vizualizacija karakter-po-karakter razlika (diff), i kratak pregled tipičnih grešaka.

8.1 Dokument 1: Vozačka dozvola (ID: 011559)



Figure 1: Originalni scan - Japanska vozačka dozvola

Metrika	Vrednost
Character Error Rate (CER)	0.3582
Word Error Rate (WER)	1.0000
Accuracy	64.18%
Similarity	71.74%
Character Precision	83.82%

Table 3: Metrike performansi OCR-a za vozačku dozvolu

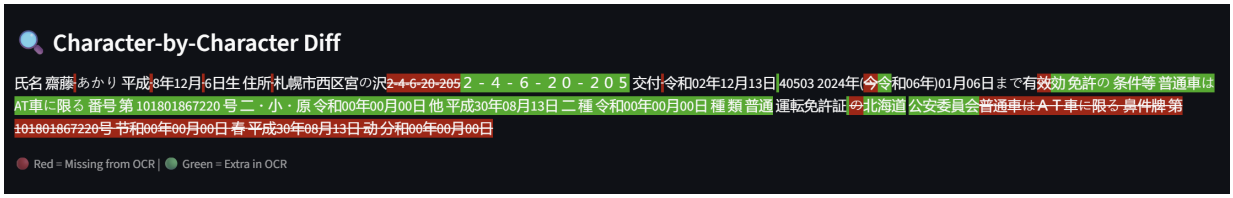


Figure 2: Character-by-Character Diff: crveno = nedostaje u OCR izlazu, zeleno = višak u OCR izlazu

Performance Metrics:

Tipične greške identifikovane:

- **Wrong kanji (令→今/分)**: “令和” pogrešno prepoznat kao “今和” ili “分和” zbog vizuelne sličnosti radikala. Ovo je najčešća greška (36% grešaka).
- **Full-width/Half-width konfuzija**: Adresa “２－４－６－２０－２０５” čitana kao “2-4-6-20-205”; “AT” kao “ＡＴ”.
- **Missing spaces**: Datum i broj spojeni bez razmaka (“令和02年12月13日40503” umesto “令和 02 年 12 月 13 日 40503”).
- **Missing characters**: Label “条件等” skoro potpuno izostavljen, OCR čita samo “の”.
- **Segmentacija**: OCR čita “運転免許証” umesto “免許の” — tekst iz pogrešnog regiona dokumenta.

8.2 Dokument 2: Pasoš (ID: 011600)

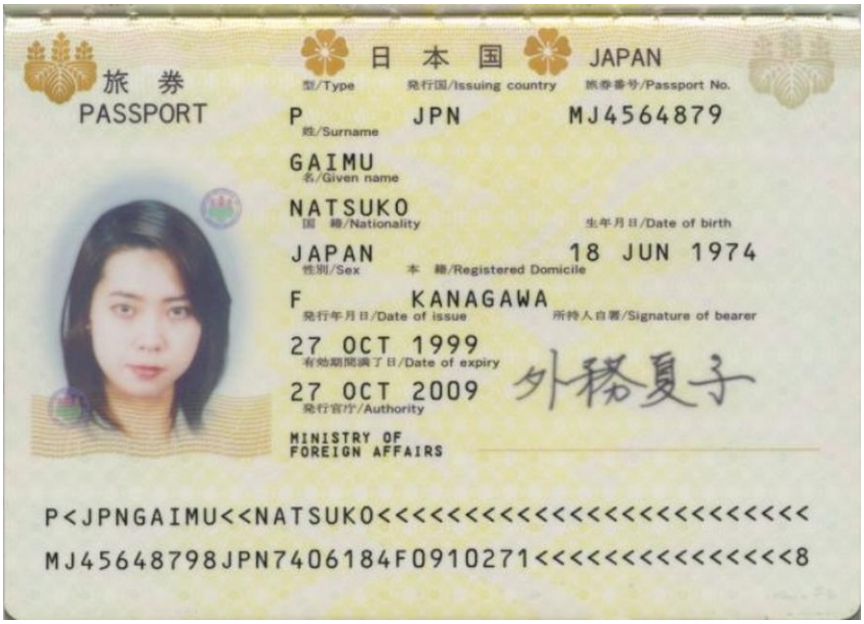


Figure 3: Originalni scan - Japanski pasoš

Metrika	Vrednost
Character Error Rate (CER)	0.5369
Word Error Rate (WER)	0.9600
Accuracy	46.31%
Similarity	33.92%
Character Precision	94.29%

Table 4: Metrike performansi OCR-a za pasoš



Figure 4: Character-by-Character Diff za pasoš

Performance Metrics:

Tipične greške identifikovane:

- **Missing characters - Labels**: OCR sistematski izostavlj a labele polja (“姓/Surname”, “名/Given name”, “国籍/Nationality”, “性別/Sex”, “発行国/Issuing country”), dok uspešno čita same vrednosti (GAIMU, NATSUKO, JAPAN). Ovo ukazuje na problem sa segmentacijom label/value parova.
- **Wrong kanji - Kontekstualna konfuzija**: OCR čita “旅券” (passport) umesto “日本” u jednom delu, a “旅券” umesto “型/Type” u drugom, verovatno zbog ponavljanja iste reči na dokumentu.
- **Ekstremna redukcija**: Fraza “日本国” (Japan nation) prepoznata kao samo “I” — drastična greška u segmentaciji ili character recognition.
- **Delimično izostavljen content**: “発行国/Issuing country” pročitan kao samo “P” (drastična redukcija).

8.3 Dokument 3: Fire Equipment License (ID: 011605)



Figure 5: Originalni scan - 消防設備士免状 (Fire Equipment License)

Metrika	Vrednost
Character Error Rate (CER)	0.8351
Word Error Rate (WER)	1.0000
Accuracy	16.49%
Similarity	20.83%
Character Precision	89.47%

Table 5: Metrike performansi OCR-a za Fire Equipment License

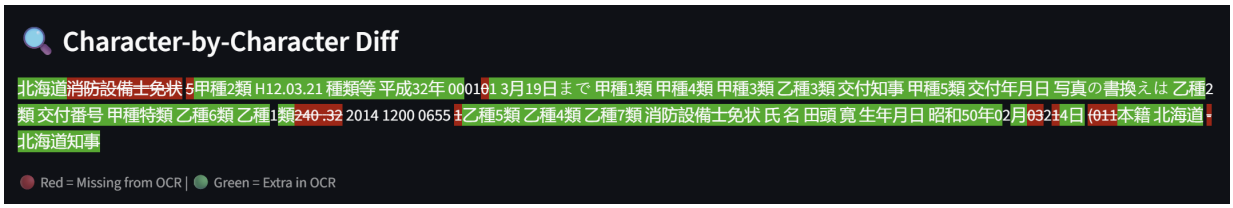


Figure 6: Character-by-Character Diff za Fire Equipment License

Performance Metrics:

Tipične greške identifikovane:

- **Totalni layout kolaps**: 0% tačnost na linijskom nivou — OCR čita tekst, ali iz potpuno pogrešnih pozicija.
- **Sistematski drift**: Labeli postaju vrednosti, vrednosti postaju labeli. Primer: naslov dokumenta “消防設備士免状” čitan umesto lokacije “北海道”; broj “501021240” čitan umesto tipa licence “甲種 2 類”.

- **Reading order failure**: Redosled čitanja potpuno pogrešan — OCR meša tabele, random delove dokumenta, ne prati strukturu polja.
- **Najgori slučaj u skupu**: Demonstrira kritičnost layout/segmentacije za OCR performanse. Problem NIJE u character recognition, već u potpunom failure-u text region detection-a.

8.4 Dokument 4: Zdravstvena kartica A (ID: 011613)



Figure 7: Originalni scan - Zdravstvena kartica tip A

Metrika	Vrednost
Character Error Rate (CER)	0.4764
Word Error Rate (WER)	1.0000
Accuracy	52.36%
Similarity	65.89%
Character Precision	84.62%

Table 6: Metrike performansi OCR-a za zdravstvenu karticu A

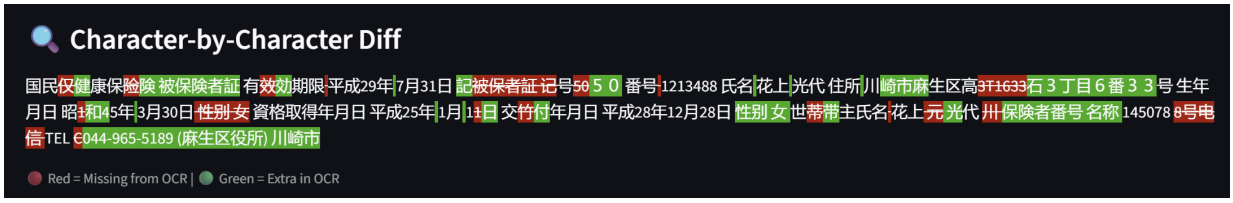


Figure 8: Character-by-Character Diff za zdravstvenu karticu A

Performance Metrics:

Tipične greške identifikovane:

- **Wrong kanji - JP/CN varijante**: Ekstremno česte zamene sa kineskim varijantama: “有効” → “有效”, “性別” → “性别”, “健康” → “☒康”, “保険” → “保者”, “世帯” → “世蒂” (7 instanci).
- **Layout/segmentacija problema**: Adresa “川崎市麻生区高石３丁目６番３３号” drastično reduk о в а н а na “川生区高 3T1633 号” — potpuna degradacija strukture.
- **Missing spaces**: “氏名花上光代” umesto “氏名 花上 光代”; datumi bez razmaka između godine i meseca.
- **Full-width/Half-width konfuzija**: “記号５０” → “☒号 50” (kineska varijanta + half-width broj).

8.5 Dokument 5: Zdravstvena kartica B (ID: 011614)

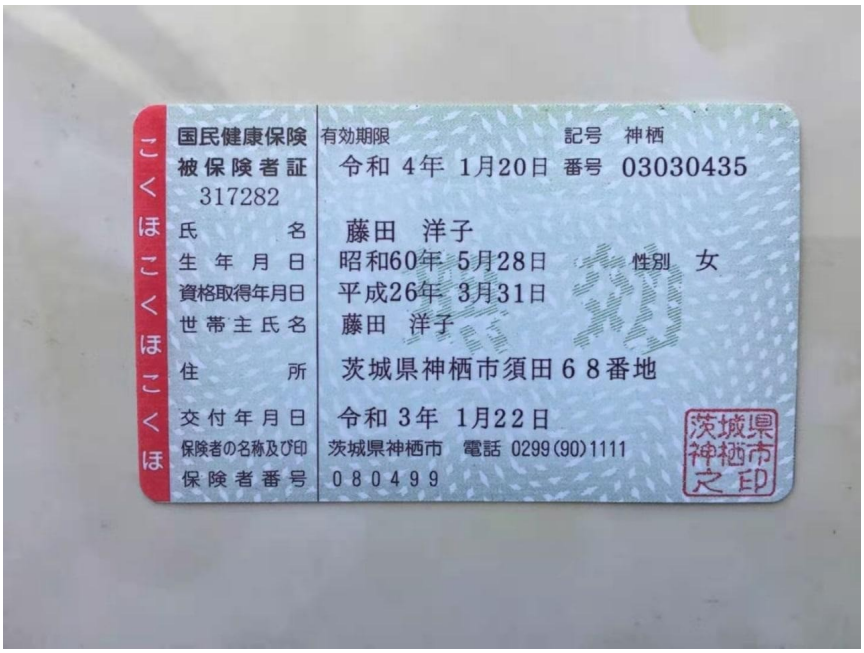


Figure 9: Originalni scan - Zdravstvena kartica tip B

Metrika	Vrednost
Character Error Rate (CER)	0.7352
Word Error Rate (WER)	1.0000
Accuracy	26.48%
Similarity	42.38%
Character Precision	89.74%

Table 7: Metrike performansi OCR-a za zdravstvenu karticu B



Figure 10: Character-by-Character Diff za zdravstvenu karticu B

Performance Metrics:

Tipične greške identifikovane:

- **Layout performanse znatno bolje**: 48.3% tačnost (duplo bolje od Kartice A), manje dramatičnih layout grešaka.
- **Wrong kanji - JP/CN varijante**: Još uvek prisutne ali ređe: “有効” → “有効”, “性別” → “性别”, “茨城県” → “⊠城⊠” (kineska prefektura).
- **Full-width space problema**: “藤田 洋子” → “藤田　洋子” (full-width space umesto normalnog).
- **Extra characters**: “令和 4 年 1 月 20 日” → “令和 4 年 1 月 20 日番号” (dodavanje “番号”).
- **Full-width/Half-width brojevi i interpunkcija**: “６８” → “68”; “0299(90) 1111” → “0299（90)1111”.

9 Zaključak

Analiza pet japanskih zvaničnih dokumenata otkriva jasnu hijerarhiju problema u OCR performansama. Dominantna kategorija grešaka su **layout/segmentacione greške**, koje u ekstremnim slučajevima (Fire Equipment License) dovode do potpunog kolapsa sistema sa 0% tačnošću uprkos relativno uspešnom prepoznavanju pojedinačnih karaktera. Problem nije u “čitanju slova”, već u fundamentalnom nerazumevanju strukture dokumenta — OCR meša labele sa vrednostima, čita regione u pogrešnom redosledu, i gubi razliku između različitih sekcija dokumenta.

Druga kategorija po učestalosti su **kanđi supstitucije** (29.5% netačnih linija), pri čemu se javljaju dva mehanizma: vizuelna sličnost karaktera (npr. “令和” → “今和”) i sistematsko “klizanje” u kineske Unicode varijante umesto japanskih (“有効” → “有效”, “性別” → “性别”). Za razliku od layout grešaka koje “zaraze” ceo dokument, kanđi greške su lokalne i potencijalno popravljive post-procesiranjem kroz rečnike i kontekstualno razumevanje.

Formatne razlike (razmaci, zenkaku/hankaku) superficijalno deluju “male”, ali u praksi su čest izvor neusaglašenosti u strogoj automatskoj validaciji. Primer: adresa “２－４－６－２０－２０５” vs “2-4-6-20-205” je vizuelno identična čoveku, ali potpuno različita stringu.

Preporuke po prioritetu:

1. **Stabilizacija layout/segmentacije**: Template-aware detekcija za poznate dokumente, robustniji text region detection, poboljšan reading order algoritam. Ovo je bottleneck sistema — bez ispravnog layout-a, sve ostalo je beskorisno.

2. **Unicode/tipografska normalizacija**: Automatska normalizacija zenkaku/hankaku prema standardu, normalizacija razmaka, standardizacija formata (telefoni, datumi). Relativno lak fix sa velikim ROI-em.

3. **Jezički post-proces**: Rečnik/frekventne fraze za zvanične dokumente ("令和", "有効期限"), preferiranje japanskih Unicode varijanti, field-specific validacija (datumi, prefekture).

Sa trenutnom tačnošću od 31.6% (36/114 linija), primena ovih mera u navedenom redosledu može realno podići performanse na >80%, uz prioritet na layout stabilizaciji koja ima najveći pojedinačni uticaj.