Benchmark analiza OCR sistema za japanske dokumente: Tesseract vs PaddleOCR vs Surya

Detaljna analiza

December 26, 2025

1 Uvod

Ovaj izveštaj predstavlja sistematsku evaluaciju tri OCR sistema (Tesseract, PaddleOCR, i Surya) na skupu japanskih dokumenata različitih tipova. Cilj istraživanja je identifikacija optimalnog OCR rešenja za japanski jezik, kao i analiza uticaja preprocessing tehnika na finalne performanse.

1.1 Potencijalni izazovi

Japanski jezik predstavlja specifičan izazov za OCR sisteme zbog:

- **Tri pisma**: Hiragana, Katakana, i Kanji (hiljade karaktera)
- **Vizuelne sličnosti**: Mnogi kanji karakteri imaju slične oblike
- **Mixed-script dokumenti**: Kombinacija japanskog i latinice
- **Raznovrsnost dokumenata**: Od čistih skenova knjiga do fotografija ID kartica

1.2 Testni skup

Korišćen je javno dostupan dataset sa Kaggle platforme:
`https://www.kaggle.com/datasets/appenlimited/ocr-image-data-of-japanese-documents`
Dataset obuhvata 11 kategorija dokumenata:

1. Badges and Passes (bedževi i propusnice)
2. Bills (računi)
3. Book Contents or Covers (sadržaj knjiga ili korice)
4. Contracts (ugovori)
5. Forms (obrasci)
6. Identity Cards (lične karte)
7. Newspapers (novine)

8. Notes (beleške)
9. Papers (naučni radovi)
10. Trade Documents (trgovinski dokumenti)
11. Whiteboard (Blackboard) (table)

2 Metodologija

2.1 Evaluaciona metrika

Kao primarna metrika korišćen je **Character Error Rate (CER)**, koji meri procenat pogrešno prepoznatih karaktera:

$$\text{CER} = \frac{\text{Substitutions} + \text{Insertions} + \text{Deletions}}{\text{Total Characters in Ground Truth}}$$

CER je odabran umesto Word Error Rate (WER) jer japanski tekst ne koristi razmake između reči na konzistentan način, što čini karakter prirodnom jedinicom merenja.

2.2 Testirani OCR sistemi

Tesseract OCR Tradicionalni OCR sistem zasnovan na pattern matching i machine learning tehnikama. Konfigurisan za japanski jezik (`jpn` language pack).

PaddleOCR Savremeni deep learning sistem sa attention/Transformer arhitekturama. Koristi globalni kontekst prilikom prepoznavanja teksta i ima eksplicitnu podršku za CJK (Chinese, Japanese, Korean) jezike.

Surya OCR Relativno nov sistem zasnovan na vision transformers. Testiran kao alternativa PaddleOCR-u.

2.3 Preprocessing tehnike

Testirane su sledeće preprocessing metode:

Baseline (Original) Slike bez ikakvog preprocessinga — direktan input u OCR.

Cropping Isecanje slike kako bi se uklonila pozadina i fokusiralo na regiju teksta.

Sauvola Threshold Naprednija thresholding tehnika koja bolje balansiše šum i kontrast.

3 Rezultati: Poređenje OCR sistema

3.1 Detaljna analiza: Tesseract vs Paddle OCR

Nakon identifikacije PaddleOCR-a kao najboljeg sistema, izvršena je detaljna analiza uticaja različitih preprocessing tehnika na Tesseract performanse.

Table 1: CER za različite Tesseract preprocessing varijante

Kategorija	Original	Crop	Threshold	Paddle	Paddle Crop	Paddle Th.
Badges/Passes	0.693	0.710	0.723	0.844	0.844	0.844
Bills	0.628	0.699	0.699	0.188	0.184	0.195
Book Contents	0.136	0.150	0.157	0.072	0.076	0.124
Contracts	0.781	0.548	0.458	0.402	0.394	0.399
Forms	0.645	0.645	0.719	0.779	0.779	0.773
Identity Cards	1.786	1.786	1.493	1.990	1.990	1.070
Newspapers	0.944	0.933	0.963	0.837	0.837	0.827
Notes	1.036	1.000	1.173	0.662	0.662	0.741
Papers	0.079	0.078	0.082	0.074	0.074	0.071
Trade Documents	1.973	1.973	1.846	0.773	0.773	0.775
Whiteboard	0.859	0.888	0.907	0.380	0.400	0.649
MEAN	**0.869**	**0.855**	**0.838**	**0.636**	**0.638**	**0.588**

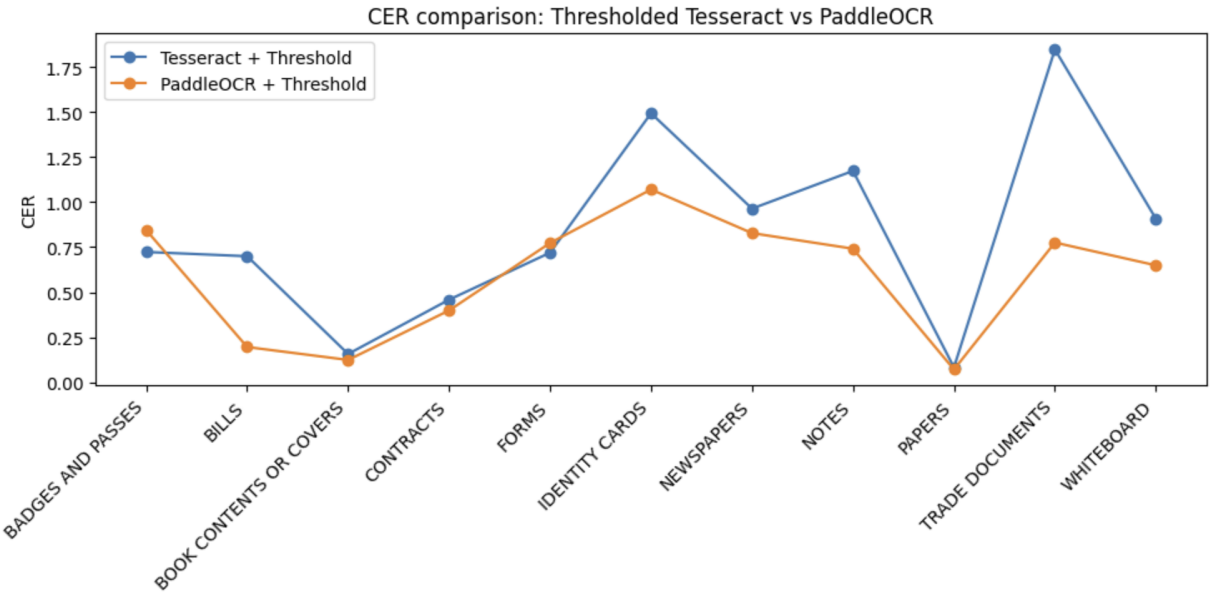


Figure 1: Vizuelno poređenje CER performansi tri OCR sistema

3.2 Uticaj preprocessinga: Komparativna analiza

Table 2: Relativno poboljšanje/pogoršanje performansi preprocessingom

Preprocessing metod	Tesseract ΔCER	PaddleOCR ΔCER
Original (Baseline)	0.000	0.000
Crop	-0.014 (+1.6%)	+0.002 (-0.3%)
Threshold	-0.031 (+3.6%)	-0.048 (+7.5%)

Zaključci o preprocessingu:

- **Tesseract**: Minimalno poboljšanje sa thresholding-om (3.6%), ali još uvek inferioran PaddleOCR-u
- **PaddleOCR**: Threshold daje 7.5% poboljšanje — **optimalna kombinacija**
- **Cropping**: Gotovo nema efekta, ponekad čak i pogoršava performanse
- **Najbolji rezultat**: **PaddleOCR + Threshold = 0.588 CER**

4 Analiza po kategorijama dokumenata

4.1 Najbolje performanse: Čisti dokumenti

Kategorije sa najnižim CER:

- **Papers (0.060 – 0.100)**: Štampani naučni radovi, standardni fontovi, visok kontrast
- **Book Contents (0.092 – 0.140)**: Skenirane knjige, profesionalna tipografija

Razlog uspeha: Minimalan šum, konzistentan font, dobro strukturiran layout, visoka rezolucija skenova.

4.2 Najlošije performanse: Kompleksni dokumenti

Kategorije sa najvišim CER:

- **Identity Cards (1.070 – 2.711)**: Fotografije kartica, kompleksan layout, mali fontovi, refleksije
- **Contracts (0.399 – 1.235)**: Gusttekst, pečati, handwriting elementi
- **Notes (0.662 – 1.173)**: Handwritten ili semi-handwritten, nestrukturirani

Razlog problema:

1. Layout kompleksnost — OCR ne razume strukturu polja
2. Fotografije umesto skenova — perspektivna distorzija, blur, refleksije
3. Mixed content — kombinacija štampanog teksta, rukopisa, grafike
4. Mali fontovi — ID kartice imaju ekstremno gust tekst

4.3 Specifičnosti po kategorijama

Table 3: Karakteristike kategorija i OCR izazovi

Kategorija	Karakteristike	Glavni OCR izazovi
Badges/Passes	Fotografije, mali tekst, logo и	Perspektiva, blur, mali font
Bills	Tabele, brojevi, struktura	Layout detection, numerička preciznost
Book Contents	Čist sken, standardni font	Minimalni (idealan slučaj)
Contracts	Gust tekst, pravni termini	Gusttekst, specifična terminologija
Forms	Polja, linije, mixed font	Razlikovanje label/value
Identity Cards	Kompleksan layout, fotografije	Layout, mali font, refleksije
Newspapers	Multi-column, različiti fontovi	Reading order, column detection
Notes	Handwriting, nestrukturirano	Handwriting recognition
Papers	Štampani tekst, dobra kvaliteta	Minimalni izazovi
Trade Documents	Tabele, brojevi, pečati	Pečati prekrivaju tekst
Whiteboard	Fotografije table, loša osvetljenost	Blur, perspektiva, low contrast

5 Diskusija

5.1 Zašto PaddleOCR nadmašuje Tesseract?

Arhitekturalne prednosti:

1. **Deep learning**: CNN + Transformer komponente omogućavaju globalni kontekst
2. **Attention mechanism**: Model ”vidi” celu sekvencu karaktera pre nego što generiše output
3. **CJK optimizacija**: Eksplicitna podrška za veliki broj karaktera (hiljade kanji)
4. **End-to-end training**: Sistem je treniran kao celina, ne kao pipeline komponenti

Tesseract ograničenja:

1. **Pattern matching**: Zavisi od predefinisanih template-a
2. **Lokalni scope**: Analizira karaktere pojedinačno bez globalnog konteksta
3. **Layout sensitivity**: Loše se nosi sa kompleksnim layout-ima

5.2 Uticaj preprocessinga

Paradoks: Preprocessing daje veće poboljšanje kod PaddleOCR-a (7.5%) nego kod Tesseract-a (3.6%).

Objašnjenje:

- PaddleOCR koristi threshold-ovanu sliku kao **jasniji signal** za feature extraction
- Tesseract nije dizajniran da maksimalno iskoristi preprocessed features
- Deep learning modeli generalno bolje generalizuju kada im se da **konzistentniji input**

5.3 Preostali problemi

Čak i najbolja konfiguracija (PaddleOCR + Threshold, CER = 0.588) pokazuje značajne greške na:

1. **Identity Cards**: Potreban je layout-aware preprocessing ili specialized model
2. **Handwritten content**: Nedovoljna podrška za rukopis
3. **Low-quality photos**: Blur, perspektiva, loše osvetljenje

6 Testiranje: Tesseract vs PaddleOCR vs Surya

Testiranje je izvršeno sa preprocessing-om (thresholded verzije) na svim kategorijama dokumenata osim za Surya OCR koji preporučuje da se ne radi preprocessing.

Table 4: CER po kategoriji dokumenata — Početno testiranje

Kategorija	**Tesseract**	**PaddleOCR**	**Surya**
Badges and Passes	0.753	0.805	0.745
Bills	0.680	0.188	0.282
Book Contents or Covers	0.140	0.092	0.094
Contracts	0.410	0.406	1.235
Forms	0.911	0.785	0.752
Identity Cards	2.711	1.100	1.776
Newspapers	1.000	0.844	0.788
Notes	0.856	0.770	1.108
Papers	0.100	0.066	0.060
Trade Documents	0.839	0.755	0.789
Whiteboard (Blackboard)	0.834	0.605	0.551
MEAN	**0.840**	**0.583**	**0.744**

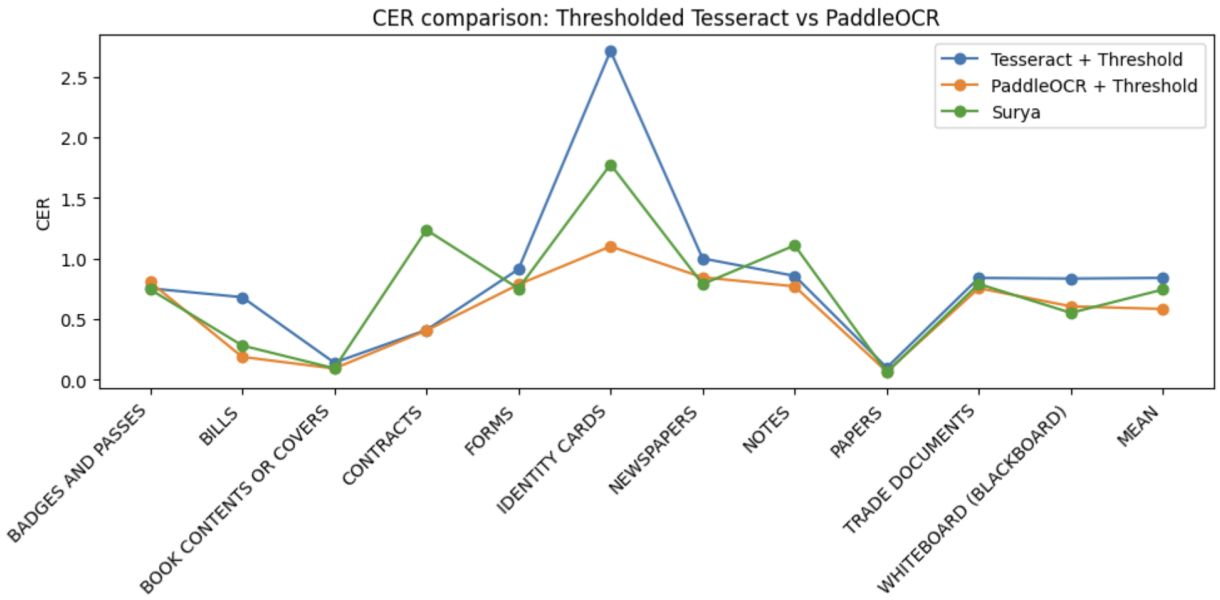


Figure 2: Vizuelno poređenje CER performansi tri OCR sistema

Ključne opservacije:

- **PaddleOCR pokazao najbolje prosečne performanse**: CER = 0.583 (30% bolje od Tesseract-a)
- **Tesseract**: Dobar na čistim dokumentima (Papers: 0.100), loš na kompleksnim (Identity Cards: 2.711)
- **Surya**: Srednje performanse, ali ekstremno loš na Contracts (1.235)
- **Kategorije sa najnižim CER**: Papers (0.060 – 0.100), Book Contents (0.092 – 0.140) — čisti fontovi, visok kontrast
- **Kategorije sa najvišim CER**: Identity Cards (1.100 – 2.711) — layout kompleksnost, fotografije

7 Budući pravci istraživanja

7.1 Napredni preprocessing

DocRes Transformer Testiranje state-of-the-art document restoration modela koji koristi vision transformers za:

- **Dewarping**: Ispravljanje perspektivne distorzije
- **Super-resolution**: Povećanje rezolucije blurry slika
- **Shadow removal**: Uklanjanje senki i neravnomernog osvetljenja
- **Noise reduction**: Inteligentno uklanjanje šuma uz očuvanje teksta

7.2 Layout-aware OCR

Integracija **layout analysis modela** pre OCR koraka:

1. Detekcija text regions (bounding boxes)
2. Klasifikacija regiona (label vs value, header vs body)
3. Određivanje reading order-a
4. OCR samo unutar detektovanih regiona

Cilj: Rešavanje problema Identity Cards i Forms kategorija gde layout kompleksnost dominira.

7.3 Proširenje test arhive

Trenutna arhiva ima ograničenja:

- Relativno mali broj slika po kategoriji
- Nebalansirana distribucija kvaliteta
- Nedostatak nekih tipova dokumenata (npr. fakture, medicinski nalazi)

Plan: Dodavanje dodatnih dataset-a i kreiranje balanced benchmark-a.

7.4 Fine-tuning PaddleOCR modela

Trenutno se koristi pretrained model. Moguće poboljšanje kroz:

- Domain-specific fine-tuning na japanskim zvaničnim dokumentima
- Data augmentation (rotacija, blur, noise injection)
- Kombinacija PaddleOCR sa language model-om za post-correction

8 Zaključak

Ovo istraživanje je sistematski evaluiralo tri OCR sistema (Tesseract, PaddleOCR, Surya) na japanskim dokumentima sa različitim nivoima kompleksnosti.

8.1 Ključni nalazi

1. **PaddleOCR pokazuje superiornost**: 30% niži CER od Tesseract-a (0.583 vs 0.840)
2. **Preprocessing značajno utiče**: Threshold preprocessing daje +7.5% poboljšanje za PaddleOCR
3. **Optimalna konfiguracija**: PaddleOCR + Sauvola/Adaptive Threshold $\rightarrow$ CER = 0.588
4. **Čisti dokumenti**: Papers i Books pokazuju CER < 0.100 (odlične performanse)
5. **Kompleksni dokumenti**: Identity Cards i Notes pokazuju CER > 1.0 (neprihvatljivo za produkciju)

8.2 Praktične preporuke

Za produkciono okruženje:

- Koristiti **PaddleOCR** kao primarni engine
- Primeniti **adaptive thresholding** preprocessing
- Implementirati **document type classification** i primeniti specifične strategije po tipu
- Za Identity Cards i slične: dodati **layout detection** pre OCR-a
- Implementirati **post-processing** validaciju (language model, dictionary lookup)

8.3 Sledeći koraci

1. **Testiranje DocRes Transformer**: Za dewarping i restoration
2. **Layout analysis integracija**: Posebno za ID Cards i Forms
3. **Proširenje test seta**: Dodatni dokumenti i balanced dataset
4. **Fine-tuning**: Domain-specific adaptacija PaddleOCR modela
5. **Hybrid approach**: Kombinacija layout analysis + OCR + language model

Sa trenutnim rezultatima, PaddleOCR + Threshold postiže **CER = 0.588**, što predstavlja solidan baseline. Međutim, za produkcijsko okruženje potrebno je ciljati CER < 0.20, što zahteva dodatne napore u preprocessing-u i post-procesiranju, posebno za kompleksne kategorije dokumenata.